



Tecnológico de Monterrey

Instituto Tecnológico y de Estudios Superiores de Monterrey

Proyecto | Lectura, Escritura, Archivos de Big Data PySpark

Integrantes del equipo 31:

Leonardo Javier Nava Castellanos	A01750595
Alejandro Jesús Mondragón Jiménez	A01795837
Eva Denisse Vargas Sosa	A01377098
Gloria María Campos García	A01422345

Materia: Análisis de grandes volúmenes de datos

Grupo: 10

Profesor: Dr. Iván Olmos Pineda

Fecha de entrega: 5 de mayo del 2026

1. Tema de interés	2
1.1. Introducción al área seleccionada	2
1.2. Justificación del tema	2
1.3. Objetivo general de la investigación	2
2. Selección del dataset	2
2.1. Nombre y origen del dataset	2
2.2. Enlace al repositorio de origen	3
2.3. Tamaño global del dataset (GB)	3
2.4. Formato de los datos (CSV, SQL, etc.)	3
3. Revisión inicial del dataset	3
3.1. Estructura de los datos (#col, #reg, tipo de datos)	3
3.2. Relevancia de los datos para el tema de investigación	4
4. Análisis del dataset	4
4.1. Estadísticas generales	4
4.2. Problemas identificados en el dataset	5
4.3. Potencial de aplicación en el área seleccionada	5
Bibliografía	5

1. Tema de interés

Movilidad Urbana y Transporte

1.1. Introducción al área seleccionada

La movilidad urbana es uno de los pilares fundamentales del funcionamiento de las grandes ciudades del mundo. En metrópolis como Nueva York, el transporte terrestre de pasajeros, en particular los taxis, constituye un sistema complejo que conecta millones de personas con sus destinos cada día, operando las 24 horas bajo condiciones dinámicas de demanda, tráfico, clima y eventos urbanos.

1.2. Justificación del tema

El dataset de viajes de los taxis amarillos de Nueva York, con cientos de millones de registros, representa una oportunidad excepcional para aplicar técnicas de Big Data y descubrir patrones que no son visibles a simple vista: ¿cuáles zonas generan mayor ingreso por viaje?, ¿en qué horarios colapsa la oferta de taxis?, ¿existe relación entre la distancia del viaje y el porcentaje de propina?, ¿cómo varía la demanda por día de la semana o por mes del año? Responder estas preguntas permite apoyar la toma de decisiones tanto a nivel operativo como estratégico, haciendo del tema de movilidad urbana un campo especialmente fértil para el análisis con Big Data.

1.3. Objetivo general de la investigación

Identificar patrones de comportamiento en los viajes de los taxis amarillos de la ciudad de Nueva York mediante el análisis de grandes volúmenes de datos históricos de transporte, con el propósito de generar insights accionables que apoyen la optimización de la distribución de flota, la predicción de demanda y la toma de decisiones en la gestión del transporte urbano.

2. Selección del dataset

2.1. Nombre y origen del dataset

Nombre: NYC Yellow Taxi Trip Data

Origen: Los datos son recopilados por los proveedores autorizados de tecnología TPEP Creative Mobile Technologies y VeriFone Inc. y publicados oficialmente por la **NYC Taxi & Limousine Commission (TLC)**, la entidad reguladora del transporte de pasajeros en la ciudad de Nueva York. El dataset fue posteriormente publicado en Kaggle por el usuario elemento.

2.2. Enlace al repositorio de origen

<https://www.kaggle.com/datasets/elemento/nyc-yellow-taxi-trip-data>

2.3. Tamaño global del dataset (GB)

El dataset comprende registros de viajes de múltiples años. En su cobertura de 2017 a 2022 contiene aproximadamente 396 millones de filas y su tamaño es de 5.79 GB aproximadamente.

2.4. Formato de los datos (CSV, SQL, etc.)

El dataset en Kaggle se distribuye en formato CSV (*Comma-Separated Values*)

3. Revisión inicial del dataset

Abrimos el dataset usando PySpark.

```
spark = SparkSession.builder.appName("NYC Yellow cab").getOrCreate()

df = spark.read.csv("ruta", header=True, sep=",", inferSchema=False)

df.show()
```

Con lo anterior ya tenemos el dataset en un objeto de PySpark, el cual usamos para hacer el análisis solicitado, pues ayuda a inspeccionar el conjunto de datos de forma que funciona para millones de registros.

3.1. Estructura de los datos (#col, #reg, tipo de datos)

# Rows:	12,210,952
# Columna	19

Columna	dtype	Valores faltantes o nulos
VendorID	StringType()	0
tpep_pickup_datetime	StringType()	0
tpep_dropoff_datetime	StringType()	0
passenger_count	StringType()	0
trip_distance	StringType()	0
pickup_longitude	StringType()	0
pickup_latitude	StringType()	0
RatecodeID	StringType()	0
store_and_fwd_flag	StringType()	0
dropoff_longitude	StringType()	0
dropoff_latitude	StringType()	0

payment_type	StringType()	0
fare_amount	StringType()	0
extra	StringType()	0
mta_tax	StringType()	0
tip_amount	StringType()	0
tolls_amount	StringType()	0
improvement_surcharge	StringType()	0
total_amount	StringType()	0

3.2. Relevancia de los datos para el tema de investigación

El dataset contiene datos generados por sistemas de transporte urbano que permite estudiar patrones de movilidad, comportamiento del usuario y eficiencia operativa en NYC.

Cada registro incluye información sobre el inicio y fin del viaje, las coordenadas geográficas, la duración del viaje, la distancia recorrida, el monto de la tarifa, el método de pago y el monto de la propina. Estos atributos permiten realizar análisis de demanda, obtener tiempos promedio de traslado, analizar los niveles de congestión vehicular, y evaluar aspectos relacionados a la sostenibilidad del transporte urbano.

4. Análisis del dataset

4.1. Estadísticas generales

	count	mean	stddev	min	max
VendorID	12210952	1.530647406	0.4990598731	1	2
tpcp_pickup_datetime	12210952			2016-03-01 0:00:00	2016-03-31 23:59:59
tpcp_dropoff_datetime	12210952			2016-02-25 9:45:01	2016-06-29 15:58:16
passenger_count	12210952	1.659580023	1.312189219	0	9
trip_distance	12210952	6.131769763	6156.482645	0	99.18
pickup_longitude	12210952	-72.87132992	8.964107682	-102.6784058	0
pickup_latitude	12210952	40.14348898	4.937995858	0	66.85681915
RatecodeID	12210952	1.040394967	0.5807341658	1	99
store_and_fwd_flag	12210952			N	Y
dropoff_longitude	12210952	-72.93678873	8.696973999	-0.1166670024	0
dropoff_latitude	12210952	40.18049525	4.790939927	0	50.79786301
payment_type	12210952	1.340919692	0.4902621291	1	4
fare_amount	12210952	12.79507845	134.0979234	-0.01	99.99
extra	12210952	0.3455599694	0.4563068911	-0.4	80
mta_tax	12210952	0.4976363227	0.04863318515	-0.5	79.3

tip_amount	12210952	1.792581816	2.54912414	-0.03	99.7
tolls_amount	12210952	0.3152554281	1.751526059	-10.5	96.62
improvement_surcharge	12210952	0.299719935	0.01230646604	-0.3	0.3
total_amount	12210952	16.04581967	134.3577729	-0.81	99.99

4.2. Problemas identificados en el dataset

Se observan inconsistencias en las fechas que corresponden a las columnas *tpep_pickup_datetime* y *tpep_dropoff_datetime*. Si bien los registros de *pickup* corresponden al mes de marzo 2016, algunos valores de *dropoff* se encuentran fuera del rango, desde los meses de febrero hasta junio. Los valores demasiado alejados del período esperado sugieren la existencia de valores corruptos o errores de captura.

Otro problema es la presencia de coordenadas geográficas inválidas. Se identifican valores de latitud y longitud iguales a cero o fuera del rango geográfico correspondiente a NYC, puede estar asociado a fallas en los dispositivos de GPS o datos faltantes mal registrados.

Asimismo, se detectan valores negativos en las variables monetarias *fare_amount*, *tip_amount*, *tolls_amount* y *total_amount*. La presencia de valores extremos sugiere posibles inconsistencias en los datos.

4.3. Potencial de aplicación en el área seleccionada

El dataset tiene un potencial de aplicación amplio en el que destacan las áreas de análisis para movilidad inteligente, planificación urbana, sostenibilidad ambiental, entre otras, en el que los resultados del análisis de los datos pueden contribuir a la optimización de rutas o reducción de tiempos de espera.

Bibliografía

NYC Taxi & Limousine Commission (TLC). (2023). NYC Yellow Taxi Trip Data [Conjunto de datos]. Kaggle. <https://www.kaggle.com/datasets/elemento/nyc-yellow-taxi-trip-data>

New York City Taxi & Limousine Commission. (2023). TLC Trip Record Data [Conjunto de datos]. NYC.gov. <https://www.nyc.gov/site/tlc/about/tlc-trip-record-data.page>