



Tecnológico de Monterrey

Instituto Tecnológico y de Estudios Superiores de Monterrey

Proyecto | Base de Datos de Big Data

Integrantes del equipo 31:

Leonardo Javier Nava Castellanos	A01750595
Alejandro Jesús Mondragón Jiménez	A01795837
Eva Denisse Vargas Sosa	A01377098
Gloria María Campos García	A01422345

Materia: Análisis de grandes volúmenes de datos

Grupo: 10

Profesor: Dr. Iván Olmos Pineda

Fecha de entrega: 12 de mayo del 2026

1. Caracterización de la población (P)	2
1.1. Definición de la población	3
1.2. Comportamientos habituales de la población	3
1.3. Identificación de variables clave	3
1.4. Dominio de cada variable (valores típicos)	4
1.5. Tabla de caracterización	4
2. Particionamiento de la base de datos (D)	5
2.1. Diseño del proceso de particionamiento	5
2.2. Combinaciones de particionamiento	7
3. Implementación en Jupyter Notebook	7
3.1. Link al cuaderno	8
3.2. Link de Archivos	8
4. Técnica de muestreo por partición	8
4.1. Selección de técnica de muestreo	8
4.2. Argumentación de representatividad	8
Bibliografía	9

1. Caracterización de la población (P)

Definición de variables:

Nombre del Campo	Descripción
VendorID	Código que indica el proveedor TPEP que generó el registro. 1. Creative Mobile Technologies 2. VeriFone Inc.
tpcp_pickup_datetime	Fecha y hora en que se activó el taxímetro.
tpcp_dropoff_datetime	Fecha y hora en que se desactivó el taxímetro.
Passenger_count	Número de pasajeros en el vehículo. Este valor es ingresado por el conductor.
Trip_distance	Distancia recorrida del viaje en millas reportada por el taxímetro.
Pickup_longitude	Longitud donde se activó el taxímetro.
Pickup_latitude	Latitud donde se activó el taxímetro.
RateCodeID	Código final de tarifa aplicado al final del viaje. 1. Tarifa estándar 2. JFK 3. Newark 4. Nassau o Westchester 5. Tarifa negociada 6. Viaje grupal
Store_and_fwd_flag	Este indicador señala si el registro del viaje fue almacenado en la memoria del vehículo antes de enviarse al proveedor, conocido como 'store and forward', debido a que el vehículo no tenía conexión con el servidor. Y = viaje almacenado y reenviado N = viaje no almacenado y reenviado
Dropoff_longitude	Longitud donde se desactivó el taxímetro.
Dropoff_latitude	Latitud donde se desactivó el taxímetro.
Payment_type	Código numérico que indica cómo el pasajero pagó el viaje. 1. Tarjeta de crédito 2. Efectivo 3. Sin cargo 4. Disputa 5. Desconocido 6. Viaje anulado
Fare_amount	La tarifa es calculada por el taxímetro en función del tiempo y la distancia.

1.1. Definición de la población

Población objetivo (P)

La población objetivo del estudio corresponde a los viajes realizados por taxis amarillos de Nueva York (Yellow Taxi Trips) registrados entre enero de 2015 y marzo de 2016.

Cada registro del dataset representa un viaje individual e incluye información temporal, geográfica, económica y operativa del servicio de taxi.

El objetivo de la caracterización es identificar los comportamientos habituales de los viajes y las variables que describen dicha población.

1.2. Comportamientos habituales de la población

Distancia - La mayoría de viajes son cortos.

Pasajeros - Predominan viajes con 1 pasajero.

Pago - Tarjeta y efectivo son los métodos más frecuentes.

Geolocalización - Coordenadas concentradas en NYC Zona urbana.

Tiempo - Hay horas pico claramente identificables.

1.3. Identificación de variables clave

Variables de caracterización identificadas:

Categoría	Variables
Temporales	tpep_pickup_datetime, tpep_dropoff_datetime
Geográficas	pickup_longitude, pickup_latitude, dropoff_longitude, dropoff_latitude
Operativas	VendorID, RatecodeID, store_and_fwd_flag
Demográficas del viaje	passenger_count
Distancia y movilidad	trip_distance
Económicas	fare_amount, tip_amount, tolls_amount, total_amount, extra, mta_tax, improvement_surcharge
Pago	payment_type

1.4. Dominio de cada variable (valores típicos)

Estadísticas descriptivas

Estadísticas numéricas

summary	passenger_count	trip_distance	fare_amount	tip_amount	tolls_amount	total_amount
count	47248845	47248845	47248845	47248845	47248845	47248845
mean	1.667039734	7.508417946	12.39218911	1.794568086	0.284367435	15.59273259
stddev	1.322092231	6487.65834	78.6177004	574.7383885	1.657184395	580.1392734
min	0	-3390583.8	-957.6	-220.8	-99.99	-958.4
max	9	19072628.8	429496.72	3950588.8	1450.09	3950611.6

1.5. Tabla de caracterización

Variable	Tipo	Dominio / Valores válidos	Estadística típica	Comentarios
VendorID	Categórica	1, 2	Predominan proveedores principales	Identifica la empresa del taxi
passenger_count	Cuantitativa discreta	1–6 pasajeros	Moda $\approx$ 1 pasajero	La mayoría de viajes son individuales
trip_distance	Cuantitativa continua	> 0 millas	Viajes cortos predominan	Existen outliers muy largos
pickup_longitude	Continua	Coordenadas NYC	Concentración urbana	Permite análisis espacial
pickup_latitude	Continua	Coordenadas NYC	Concentración urbana	Permite análisis espacial
RatecodeID	Categórica	1–6	Tarifa estándar domina	Identifica tipo de tarifa

store_and_fwd_flag	Binaria	Y/N	Predomina N	Indica almacenamiento temporal
payment_type	Categórica	1–6	Tarjeta y efectivo predominan	Describe método de pago
fare_amount	Continua	> 0 USD	Tarifas medias/bajas predominan	Relacionada con distancia
tip_amount	Continua	≥ 0 USD	Muchas propinas bajas	No incluye propinas en efectivo
tolls_amount	Continua	≥ 0 USD	Mayoría = 0	Solo algunos viajes incluyen peajes
total_amount	Continua	> 0 USD	Distribución sesgada	Incluye tarifa total
tpep_pickup_datetime	Temporal	Fechas válidas	Horas pico visibles	Permite análisis temporal
tpep_dropoff_datetime	Temporal	Fechas válidas	Similar al pickup	Permite calcular duración

2. Particionamiento de la base de datos (D)

Con el propósito de elaborar una muestra representativa de la población de usuarios de taxis amarillos en la ciudad de Nueva York, se diseñó un proceso de segmentación de la base de datos (D) empleando variables asociadas con los patrones de movilidad urbana y el transporte.

El objetivo de este particionamiento radica en dividir la base de datos inicial en subconjuntos homogéneos que reflejen las diversas pautas de movilidad presentes en la urbe. Esta metodología busca minimizar los sesgos durante el proceso de muestreo y garantizar que la muestra final conserve las características más significativas de la población objetivo.

La selección de las variables para el proceso de particionamiento se fundamentó en el comportamiento temporal de los trayectos y la distancia recorrida, dado que estas variables facilitan la identificación de las distintas dinámicas del transporte urbano observadas en la población estudiada.

2.1. Diseño del proceso de particionamiento

Para construir las particiones de la base de datos se utilizaron las siguientes variables:

Variable	Tipo	Descripción
time_period	Categórica derivada	Representa el periodo del día en el que ocurrió el viaje

distance_category	Catégorica derivada	Representa el tipo de desplazamiento según la distancia recorrida
-------------------	---------------------	---

Ambas variables fueron construidas a partir de variables originales del conjunto de datos (dataset):

- time_period fue generada a partir de la variable tpep_pickup_datetime.
- distance_category fue generada a partir de la variable trip_distance.

La selección de estas variables se efectuó debido a que representan patrones fundamentales de movilidad urbana, lo que permite distinguir los viajes según el momento del día y la naturaleza del desplazamiento realizado.

Para cada variable se definieron los siguientes valores posibles:

Variable	Tipo	Descripción
time_period	Madrugada, mañana, tarde y noche	Clasifica los viajes según la hora de inicio
distance_category	Corta, media, larga	Clasifica los viajes según la distancia recorrida

La variable time_period se definió utilizando los siguientes intervalos de horarios

Periodo	Intervalo
Madrugada	00:00 – 05:59
Mañana	06:00 – 11:59
Tarde	12:00 – 17:59
Noche	18:00 – 23:59

La variable distance-category fue definida mediante rangos de distancia:

Categoría	Distancia
Corta	Menor a 2 millas
Media	Entre 2 y 10 millas
Larga	Mayor a 10 millas

2.2. Combinaciones de particionamiento

A partir del cruce de las variables time_period y distance_category se generaron diferentes combinaciones de particionamiento.

Cada combinación representa una regla específica de particionamiento que podrá ser utilizada para dividir la base de datos original en subconjuntos con características homogéneas. Las probabilidades de ocurrencias de cada combinación fueron calculadas mediante la frecuencia relativa conjunta de ambas variables.

Combinación	Regla de particionamiento	Probabilidad
1	time_period → Madrugada, distance_category → Corta	0.0070
2	time_period → Madrugada, distance_category → Media	0.0087
3	time_period → Madrugada, distance_category → Larga	0.0016
4	time_period → Mañana, distance_category → Corta	0.5823
5	time_period → Mañana, distance_category → Media	0.3555
6	time_period → Mañana, distance_category → Larga	0.0448

Cada partición generada agrupa registros con características similares de movilidad urbana, permitiendo construir subconjuntos representativos para etapas posteriores de muestreo y aprendizaje.

Partición	Características
Madrugada + Corta	Viajes breves realizados durante horarios nocturnos de baja movilidad
Madrugada + Media	Viajes de distancia moderada realizados durante la madrugada
Madrugada + Larga	Viajes extensos y poco frecuentes durante horarios nocturnos
Mañana + Corta	Viajes urbanos cortos asociados a movilidad cotidiana y laboral
Mañana + Media	Traslados urbanos de distancia media durante horas de actividad
Mañana + Larga	Viajes largos realizados durante periodos de alta movilidad

Estas reglas de particionamiento podrán permitir aplicar técnicas de muestreo específicas para recuperar instancias representativas de cada subconjunto generado.

3. Implementación en Jupyter Notebook

El código permite realizar el filtrado y recuperación de registros de la base de datos D, que está compuesta de aproximadamente 47M de datos, asegurando que dichos registros cumplan con las reglas de particionamiento definidas en la sección 2.

3.1. Link al cuaderno

Este código considera la unión de los datos provenientes de cuatro archivos CSV correspondientes a los meses de enero de 2015, enero de 2016, febrero de 2016 y marzo de 2016, los cuales fueron utilizados como base para aplicar las reglas de particionamiento y validar el correcto funcionamiento del proceso. El jupyter notebook puede consultarse a través del siguiente enlace: https://drive.google.com/file/d/16dl_Fyb7PK3n9g9rhWb31MrKWQqV7s17/view?usp=drive_link

3.2. Link de Archivos

Los archivos utilizados en la implementación fueron obtenidos del conjunto de datos público disponible de Kaggle: NYC Yellow Taxi Trip Data del siguiente enlace: <https://www.kaggle.com/datasets/elemento/nyc-yellow-taxi-trip-data>. Estos archivos se encuentran organizados en la carpeta de trabajo del proyecto y constituyen la base de datos D empleada para la etapa de prueba y validación del código, a la que se puede acceder a través del siguiente enlace: https://drive.google.com/drive/folders/1bRg8ElQOP1FIgqfzWbazzXyE2aaNJY5r?usp=drive_link.

4. Técnica de muestreo por partición

4.1 Selección de técnica de muestreo

Para recuperar instancias representativas de cada una de las seis particiones definidas en la sección 2, se propone aplicar muestreo aleatorio simple (MAS) dentro de cada partición de forma independiente.

El muestreo aleatorio simple consiste en seleccionar un subconjunto de n registros de una partición de tamaño N , de forma que cada registro tenga exactamente la misma probabilidad de ser seleccionado ($1/N$), y cualquier subconjunto posible de tamaño n tenga la misma probabilidad de conformar la muestra. Esta selección se realiza sin reemplazo, lo que garantiza que ningún registro sea incluido más de una vez en el conjunto recuperado.

La elección de esta técnica responde directamente a las características del diseño de particionamiento adoptado. Dado que el proceso de segmentación ya dividió la base de datos en subconjuntos internamente homogéneos, agrupando registros con comportamientos similares en cuanto al periodo del día y la distancia del viaje, cada partición actúa como un universo reducido y relativamente uniforme. Dentro de este universo no existe justificación para privilegiar ningún registro sobre otro, por lo que el muestreo aleatorio simple es la técnica más adecuada para garantizar equidad en la selección.

En términos de implementación práctica, dado el volumen de datos por partición, se puede emplear la técnica de reservoir sampling (muestreo de reservorio), que permite seleccionar ' n ' registros de forma uniformemente aleatoria sin necesidad de cargar la partición completa en memoria.

4.2 Argumentación de representatividad

El muestreo aleatorio simple dentro de cada partición evita la introducción de sesgos por las siguientes razones. En primer lugar, garantiza la equi-probabilidad de selección, ya que cada registro dentro de una partición tiene idéntica probabilidad de ser escogido, lo que elimina cualquier preferencia sistemática hacia ciertos viajes.

En segundo lugar, evita la exposición a patrones temporales internos: a diferencia del muestreo sistemático, donde se toma cada k -ésimo registro, el MAS no corre el riesgo de coincidir con ciclos o periodicidades presentes en el orden de los registros, como picos de

demanda o efectos de día de semana, que podrían distorsionar la muestra. Finalmente, al no depender de ningún criterio subjetivo para determinar qué registros incluir, el proceso es completamente reproducible y auditable.

La garantía de representatividad de la muestra M respecto a la población P opera en dos niveles complementarios. A nivel de partición, el MAS asegura que los registros seleccionados reflejen la distribución real de las variables internas de cada subgrupo, como `fare_amount`, `passenger_count` o `payment_type`, sin distorsionar ninguna característica propia de la partición. A nivel global, para que la muestra total M sea representativa de la población P, el tamaño de muestra extraído de cada partición debe ser proporcional al peso relativo de dicha partición en el conjunto completo, conforme a las probabilidades reportadas en la Tabla de Combinaciones de la sección 2.2. De esta forma, las particiones más frecuentes como Mañana + Corta (0.5823) y Mañana + Media (0.3555) aportarán más instancias, en concordancia con su representación real en la población.

Para las particiones con baja frecuencia de ocurrencia, en particular Madrugada + Larga (0.0016), se recomienda garantizar un tamaño mínimo de muestra que permita su uso efectivo en las etapas de entrenamiento y prueba. En estos casos se podrá aplicar un ajuste controlado de sobremuestreo, extrayendo un número de instancias ligeramente superior al que correspondería por proporción estricta, sin comprometer la validez del proceso, dado que la homogeneidad interna de la partición continúa siendo asegurada por el diseño del particionamiento.

En conclusión, la combinación del particionamiento estratificado por `time_period` y `distance_category` con el muestreo aleatorio simple dentro de cada estrato constituye un esquema de muestreo aleatorio estratificado que minimiza la varianza entre estratos y garantiza que la muestra M capture las principales dinámicas de movilidad urbana presentes en la población de viajes de taxi amarillo de Nueva York.

Bibliografía

NYC Taxi & Limousine Commission (TLC). (2023). NYC Yellow Taxi Trip Data [Conjunto de datos]. Kaggle. <https://www.kaggle.com/datasets/elemento/nyc-yellow-taxi-trip-data>

New York City Taxi & Limousine Commission. (2023). TLC Trip Record Data [Conjunto de datos]. NYC.gov. <https://www.nyc.gov/site/tlc/about/tlc-trip-record-data.page>